

스마트 아일랜드를 위한 주의 집중 메커니즘 기반의 확률론적 단기 일사량 예측 기법 (A Probabilistic Short-Term Solar Radiation Prediction Scheme Based on Attention Mechanism for Smart Island)

정 승 민 [†] 문 지 훈 [†] 박 성 우 [†] 황 인 준 ^{††}
 (Seungmin Jung) (Jihoon Moon) (Sungwoo Park) (Eenjun Hwang)

요 약 스마트 시티와는 달리 섬이라는 지형적 특징을 기반으로 하는 스마트 아일랜드에서는 신재생 에너지 발전이 매우 중요하다. 한국에서의 대표적인 신재생에너지로는 태양광과 풍력 에너지가 있으며, 특히 태양광 발전은 제주도에서 많이 보편화되어 있다. 태양광 발전시스템에서 더욱 효과적인 전력 생산을 위해서는 미래의 일사량 예측값이 고려되어야 하지만, 기상청에서는 온도, 습도, 풍속과 같이 다른 기상 요소들과는 다르게 일사량에 대한 예측값을 제공하고 있지 않다. 따라서 태양광 발전시스템의 수요관리를 위해서는 충분히 신뢰할 수 있는 정확도 높은 일사량 예측 모델이 필요하다. 이에 본 논문은 장단기 메모리 네트워크 기반의 확률론적 단기 일사량 예측 모델을 제안한다. 구체적으로, 기상청에서 제공하는 제주도의 서로 다른 두 지역의 과거 일사량 정보와 기상 요소 데이터들을 수집하며, 예측 모델의 입력 변수 구성을 위해 수집된 데이터에 대해 전처리 과정을 수행한다. 다음으로 주의 집중 메커니즘 기반 장단기 메모리 네트워크를 이용하여 일사량 예측 모델을 구축한다. 마지막으로 다양한 심층 학습 모델과의 비교 및 분석을 통해 제안한 모델의 타당성을 검증한다.

키워드: 스마트 아일랜드, 일사량 예측, 주의 집중 메커니즘, 장단기 메모리 네트워크, 심층 학습

Abstract Compared to smart cities, renewable energy is particularly important in smart islands, because it depends on the territorial region of the island. The types of renewable energy typically used in Korea are photovoltaic (PV) and wind energy; PV power generation is particularly used on Jeju island. To achieve more efficient power generation using the PV system, there is a need for more accurate prediction for solar radiation. However, unlike other meteorological factors such as temperature, humidity, and wind speed, the Korea Meteorological Administration (KMA) does not provide any prediction data for solar radiation. Therefore, to enhance the power energy management of the PV system, a reliable and accurate prediction model for solar radiation is required. In this paper, we propose a probabilistic short-term solar radiation prediction model based on long short-term memory (LSTM) networks. Specifically, we collect historical solar radiation data and weather data from two different regions in Jeju Island provided by the KMA, then perform several types of

· 이 연구는 한국전력공사의 2018년 착수 에너지 거점대학 클러스터 사업(R18XA05)과 2019년도 정부(과학기술정보통신부)의 재원으로 한국연구재단-에너지클라우드 기술개발사업의 지원을 받아 수행된 연구임 (No. 2019M3F2A1073184).
 · 이 논문은 2019 한국컴퓨터종합학술대회에서 '심층 학습에 기반한 제주도의 단기 일사량 예측 기법'의 제목으로 발표된 논문을 확장한 것임

[†] 학생회원 : 고려대학교 전기전자공학과
 jmkstcom@korea.ac.kr
 johnny89@korea.ac.kr
 psw5574@korea.ac.kr

^{††} 종신회원 : 고려대학교 전기전자공학과 교수(Korea Univ.)
 ehwang04@korea.ac.kr
 (Corresponding author임)

논문접수 : 2019년 8월 20일
 (Received 20 August 2019)
 논문수정 : 2019년 9월 24일
 (Revised 24 September 2019)
 심사완료 : 2019년 9월 25일
 (Accepted 25 September 2019)

Copyright©2019 한국정보과학회 : 개인 목적이거나 교육 목적인 경우, 이 저작물의 전체 또는 일부에 대한 복사본 혹은 디지털 사본의 제작을 허가합니다. 이 때, 사본은 상업적 수단으로 사용할 수 없으며 첫 페이지에 본 문구와 출처를 반드시 명시해야 합니다. 이 외의 목적으로 복제, 배포, 출판, 전송 등 모든 유형의 사용행위를 하는 경우에 대하여는 사전에 허가를 얻고 비용을 지불해야 합니다.
 정보과학회 컴퓨팅의 실제 논문지 제25권 제12호(2019. 12)

preprocessing for the collected data for input variable configuration of the prediction model. Next, we construct an attention mechanism-based LSTM network model for probabilistic solar radiation prediction. Finally, we analyze and compare our model with various deep neural network models to confirm its validity.

Keywords: smart island, solar radiation prediction, attention mechanism, long short-term memory networks, deep learning

1. 서 론

최근, 기후 변화와 에너지 위기에 대응하기 위해, 신재생에너지와 연관된 스마트 그리드 기술이 크게 주목받고 있다[1]. 스마트 그리드는 기존의 전력망에 정보통신기술을 접목한 지능형 전력망을 의미한다[1-3]. 또한, 이는 소비자와 공급자가 전력 생산과 소비 정보를 양방향으로 주고받으며 에너지 사용을 최적화할 수 있다[2,3]. 신재생에너지는 스마트 그리드의 핵심 요소 중 하나로 태양광, 풍력 등을 통해 에너지를 생산하여 목적에 맞게 에너지를 사용할 수 있다. 스마트 그리드와 다르게 제주도과 같이 섬이라는 지역적 특징을 가진 스마트 아일랜드의 경우에는 에너지 자원이 한정적이다. 신재생에너지 발전은 한정적인 에너지 자원 문제를 해결할 수 있어 많은 주목을 받고 있다. 그중에서 태양광 발전은 제주도에서 가장 유용하게 쓰일 수 있는 신재생에너지 자원이다.

최근 정부에서는 신재생에너지와 관련된 다양한 지원 정책을 펼치고 있어[4] 태양광 발전시스템의 수요가 증가하고 있다. 태양광은 석탄, 석유 등의 화석 발전과는 달리 환경친화적이고 한정적이지 않은 자원이다[5,6]. 또한, 시공비용이 다른 발전시스템에 비해 적다는 장점이 있다[5]. 태양광 발전시스템은 다양한 기상 요인들에 의해 전력 생산량에 큰 영향을 받으며, 특히 일사량은 태양광 발전의 핵심 요소이다[6,7]. 하지만 전력을 효율적으로 생산하기 위해 태양광 발전시스템에 영향을 끼치는 요소 중 날씨, 기온, 습도 등은 기상청의 일기예보를 통해 데이터를 받을 수 있지만, 가장 중요한 요소인 일사량에 대한 예측값은 일기예보를 통해 얻을 수 없다[5]. 따라서 일사량에 관한 정확도 높은 예측 모델이 필요하다.

현재까지 태양광 발전시스템을 위한 일사량 예측 모델에 관한 연구가 진행되었다[8-11]. [8]은 해당 지역의 일일 일사 지속시간, 날씨 및 시간, 일일 최대 온도 등을 입력 변수로 구성한 ANN(Artificial Neural Network) 기반의 일사량 예측 모델을 제안하였고, 통계적 접근 방식과 비교하였을 때 우수한 성능을 나타내었다. [9]는 중국 28여 개의 지역의 기상 데이터 간의 상관관계를 분석하여 다중선형회귀분석 기반의 일사량 예측 모델을 제안하였다. [10]은 국내 기상청의 실시간 기상정보를 활용하여 3가지 기계 학습 모델인 RF(Random Forest), ANN, SVM(Support Vector Machine)을 기반으로 일

사량 및 태양광 발전량 예측모델을 제안하였으며, 실험 결과 RF가 가장 좋은 예측 성능을 나타내었다. [11]은 목포 기상대에서 예보하는 기상 데이터와 영암 태양광 발전소의 발전량 데이터를 이용하여 심층 학습 기법인 DNN(Deep Neural Network), RNN(Recurrent Neural Network), LSTM(Long Short-Term Memory) 네트워크 기반의 단기 태양광 발전량 예측 모델을 제안하였다. 실험 결과, LSTM 네트워크가 가장 좋은 결과를 나타내었다.

이뿐만 아니라 일사량을 예측하는 다양한 연구들이 활발히 진행되고 있다. 하지만 국내에서 제안된 인공지능을 이용한 일사량 예측에 관한 연구는 입력 변수로 운량과 기압 등을 주로 사용하나 기상청 동네예보에는 운량과 기압에 대한 예보를 제공하지 않는다[12]. 그리하여, 스마트 그리드뿐만 아니라 제주도와 같은 스마트 아일랜드 구축에서 다소 사용하기 어렵다는 단점이 있다. 또한, 통상적인 통계 기법은 일사량과 밀접한 연관이 있는 다른 외부 요인들을 효과적으로 반영하기 어렵다.

이를 개선하기 위하여, 본 연구는 일사량 예측을 위한 주의 집중 메커니즘(Attention Mechanism) 기반의 장단기 메모리(Long Short-Term Memory; LSTM) 모델을 제안한다[13,14]. 제안하는 모델은 일기예보를 통해서 얻을 수 있는 변수들만을 사용하여 예측 모델을 학습한다. 따라서 일기예보에서 제공되지 않는 데이터를 입력 변수로 사용한 모델들과 달리 실생활에서도 적용할 수 있다. 또한, 실시간 태양광 발전시스템 스케줄링을 위해 Many-To-Many 방식을 사용하여 현재 시점의 다음 시점부터 하루 뒤 시점까지 모든 시간대의 일사량을 예측한다. 제안한 모델은 인공 신경망 기법의 하나인 SNN(Shallow Neural Network)과 DNN, LSTM 네트워크 모델들과 비교하여 예측 성능을 확인한다.

본 논문의 구성은 다음과 같다. 2장에서는 예측 모델을 구성하기 위한 데이터 전처리 과정에 대해 기술한다. 3장에서는 일사량 예측을 위한 주의 집중 메커니즘 기반의 LSTM 네트워크 모델 구성에 대해 설명한다. 4장은 본 논문에서 제안한 모델의 성능을 검증하기 위한 비교 모델에 대해 기술하며, 5장에서는 예측 모델에 대한 실험 결과에 대해 기술한다. 마지막으로 6장에서는 본 논문의 실험 결과에 대한 평가 및 향후 연구 방향의 제시와 함께 결론을 맺는다.

2. 입력 변수 구성

2.1 데이터 수집

본 논문에서는 확률론적 일사량 예측 모델을 구성하기 위해, 입력 변수로 날씨/시간, 기상 요인 및 과거 일사량 정보를 고려한다. 기상 요인 데이터는 기상자료개방포털의 종관기상관측에서 제주도에 속해있는 지점들을 고려하였다. 기상청은 일도1동(제주), 고산리(고산), 서귀포, 성산읍(성산)으로 총 4가지 지점에서 제주도의 기상 데이터를 수집하고 있다. 본 논문에서 고려하는 지점의 기상 데이터는 기상 요인과 일사량 정보가 함께 포함된 일도1동과 고산리 지역으로 선정하였다. 데이터의 수집 기간은 2011년부터 2018년까지 총 8년간 오전 8시부터 오후 6시까지이며, 실제 날씨, 기온, 습도, 풍속, 일사량 정보 등을 수집하였다. 기상청에서 제공하는 종관기상관측 데이터는 지중 온도, 지면 온도, 전운량, 일조 등 위에서 기술한 요인보다 더 많은 기상 요인들을 제공하지만, 본 논문에서 제안한 예측 모델은 하루 뒤의 일사량 예측이 목표이므로, 기상청의 동네예보에서 제공하는 날씨, 기온, 습도, 풍속만을 사용하였다[12].

2.2 결측치 보완

수집한 기상 요인 데이터에서 결측치가 발생 시 -1로 표시되어 있으며, 변수마다 전체 데이터에서 약 0.1%의 결측치가 존재하였다. 기온, 습도, 풍속, 일사량은 연속형 데이터의 특징을 가지므로 선형 보간법을 통하여 결측치를 보완하였고, 날씨의 경우 데이터가 1부터 4까지의 범주형 변수값으로 나타나므로 근접 데이터와의 유사성을 고려하여 로지스틱 회귀 분석으로 결측치를 보완하였다.

2.3 데이터 전처리

효과적인 예측 모델의 학습을 위해, 수집한 변수들을 표 1과 같이 정규화를 수행하였다. 데이터의 특성을 고려하여 변수마다 다른 정규화 방법을 선택하였으며, 정규화 방법에는 One-Hot Encoding, Standardization 기법이 사용되었다.

시간 정보 데이터의 경우 날씨의 주기성을 반영하기 위해, 식 (1), (2)와 같이 1차원 데이터를 2차원 공간의

표 1 변수별 정규화 방법

Table 1 Normalization Methods by Each Input Variable

| Input Variable | Normalization Method |
|---------------------|----------------------|
| Weather Information | One-Hot Encoding |
| Hour | One-Hot Encoding |
| Humidity | Standardization |
| Wind Speed | Standardization |
| Temperature | Standardization |
| Solar Radiation | Standardization |




그림 1 날씨 데이터 전처리 예시

Fig. 1 Example of Date Data Preprocessing

연속적인 데이터로 증강하였다[12]. 식 (1)과 (2)의 입력 변수로는 1월 1일을 1일로 하고 12월 31일을 365일로 하는 Julian Date를 사용하였다. 단, 2012년과 2016년은 1년이 366일에 해당하는 윤년이므로, 식에서 나누는 상수도 365가 아닌 366으로 바꾸어 적용하였다. $Date_x$, $Date_y$ 는 사용한 입력 변수이며, EOM은 End of Month의 약어로, 속한 달의 마지막 일을 뜻한다. month는 월, day는 일을 뜻한다. 날씨 데이터에 관한 전처리 예시를 그림 1에 나타내었다.

$$Date_x = \sin(360^\circ \times (\sum_{i=1}^{month-1} EOM + day) / 365) \quad (1)$$

$$Date_y = \cos(360^\circ \times (\sum_{i=1}^{month-1} EOM + day) / 365) \quad (2)$$

$$x_{\neq w} = \frac{x - \mu}{\sigma} \quad (3)$$

연속형 데이터인 습도, 풍속, 기온, 일사량 데이터의 경우, 식 (3)을 이용한 Standardization을 사용하였다. $x_{\neq w}$ 는 사용한 입력 변수이고, x 는 원본 데이터, μ 는 원본 데이터의 평균, σ 는 원본 데이터의 표준편차를 뜻한다. 날씨 데이터는 1부터 4까지 등간척도로 맑음, 구름 조금, 구름 많음, 흐림으로 총 4가지로 구성되어 있다. 또한, 시간 정보도 날씨 정보와 마찬가지로 등간척도로 구성되어 있다. 일사량의 경우는 낮 시간대인 12시부터 2시까지 가장 많은 양을 보이므로, 이러한 변수들을 더욱 효과적으로 학습하기 위해 해당 데이터가 속한 경우에는 1, 그렇지 않은 경우에는 0의 값을 부여하는 One-Hot Encoding을 적용하였다.

추가로 최근 일사량의 트렌드를 반영하기 위해, 예측 시점의 하루 전 습도, 날씨, 풍속, 기온 그리고 일사량 정보를 입력 변수로 함께 반영하였다. 최종적으로 데이터 전처리와 결측치 보완을 통하여 총 30개의 입력 변수와 32,143개의 튜플로 구성된 2개 지역의 데이터 셋을 구축하였다.

3. 예측 모델 구성

이 장에서는 주의 집중 메커니즘 기반의 LSTM 네트워크를 이용한 단기 일사량 예측 모델에 대해 설명한다. 모델은 그림 2와 같이 구성되어 있다. 먼저, 2장에서 구성한 30개의 변수들을 입력으로 이용한다. 다음으로, 시계열 데이터 예측에 효과적인 심층 학습 기법인 LSTM 네트워크를 기반으로 일사량 예측 모델을 구성한다. 이는 3.1절에 더욱 자세히 기술한다. 다음으로 LSTM 모델의 성능을 향상하기 위해, 모델이 특정 벡터에 주목하게 만들어 모델의 성능을 높이는 기법인 주의 집중 메커니즘 모델을 구성한다[15]. 이는 3.2절에 자세히 기술한다.

3.1 Long Short-Term Memory 모델링

LSTM은 기존 RNN의 장기 의존성 문제를 해결하기 위해 제안된 모델로 시계열 데이터 학습에 효과적이다 [13,14]. 본 모델의 목적은 실시간 스마트 아일랜드 운영 스케줄링을 위한 일사량 예측이므로 예측 시점의 다음 시점부터 하루 전(Day-Ahead) 시점까지의 일사량 예측을 목표로 한다. 그리하여, 그림 2와 같이 Many-To-Many 방식으로 하루 전 예측이 가능하도록 11개의 Sequence 길이로 구성하였다. 은닉층의 수는 2개로 설정하였고, 활성화 함수로 식 (4)와 같이 SELU(Scaled Exponential Linear Units)[16]을 사용하여 기울기 소실(Vanishing Gradient)과 폭주(Exploding) 문제를 해결하였다. λ 와 α 는 고정된 상수이고, x 는 입력값이다.

$$SELU(x) = \lambda \begin{cases} x & \text{if } x > 0 \\ \alpha e^x - \alpha & \text{if } x \leq 0 \end{cases} \quad (4)$$

손실 함수로는 이상치에 덜 민감한 Huber Loss[17]를 적용하였고, $\delta=1$ 로 설정하였다. δ 는 고정된 상수이다. Huber Loss의 식은 (5)와 같다.

$$Loss_{\delta}(y, f(x)) = \begin{cases} \frac{1}{2}(y - f(x))^2 & \text{for } |y - f(x)| \leq \delta, \\ \delta|y - f(x)|^2 & \text{otherwise.} \end{cases} \quad (5)$$

학습 시 최신 기울기를 더욱 효과적으로 반영하기 위해 최적화 알고리즘으로 RMSProp[18]를 사용하였다. 또한, 학습의 과적합(Overfitting)을 막기 위해 드롭아웃(Dropout) 방식을 이용하여 은닉층의 가중치를 조절하였다. LSTM 모델을 구성한 뒤에, 모델 학습에 고려해야 하는 초매개변수로 Learning Rate와 Epoch 등이 있다. Learning Rate가 큰 경우에는 Training Epoch을 작게 설정하기 때문에 학습 시간은 짧지만, 최적의 결과가 나오지 않을 가능성이 있다. 또한, Learning Rate가 작은 경우에는 최적의 해를 찾을 수 있다는 장점이 있지만, Training Epoch 당 Weight의 변화량이 적으므로 학습에 오랜 시간이 소요된다. 본 논문은 예측치 보완에 대한 예측 성능을 더욱 정밀하게 평가하기 위해, Batch Size는 11, Learning Rate는 0.000001, Epoch은 5,000으로 설정하였다.

3.2 주의 집중 메커니즘 구성

시계열 예측 방식에서 Sequence-To-Sequence 모델은 입력의 길이가 길어짐에도 불구하고 모든 입력 변수에 집중하여 학습하므로, 예측 정확도가 떨어지는 문제가 발생한다. 이러한 문제를 해결하기 위해, 기계번역 분야에서 주의 집중 메커니즘(Attention Mechanism)이 제안되었다[14,15]. 주의 집중 메커니즘은 입력으로부터 벡터를 만드는 부분인 인코더와 인코더가 출력한 벡터를 입력으로 하여 종속 변수를 출력하는 부분인 디코더로 구성되어 있다. 디코더 부분에서 인코더와의 유사도를 값으로 나타내어 높은 유사도를 나타내는 부분에 모델 학습을 집중하므로 정확한 예측 성능을 기대할 수 있다[14].

본 논문은 이전에 제안한 LSTM 기반의 일사량 예측 모델[19]보다 향상된 단기 일사량 예측을 위해, 앞서 기술한 주의 집중 메커니즘을 적용한다. 이를 통해 LSTM 모델이 특정 벡터에 주목하게 만들어 더욱 정확한 확률론적 단기 일사량 예측을 기대할 수 있다. 그림 2에 주

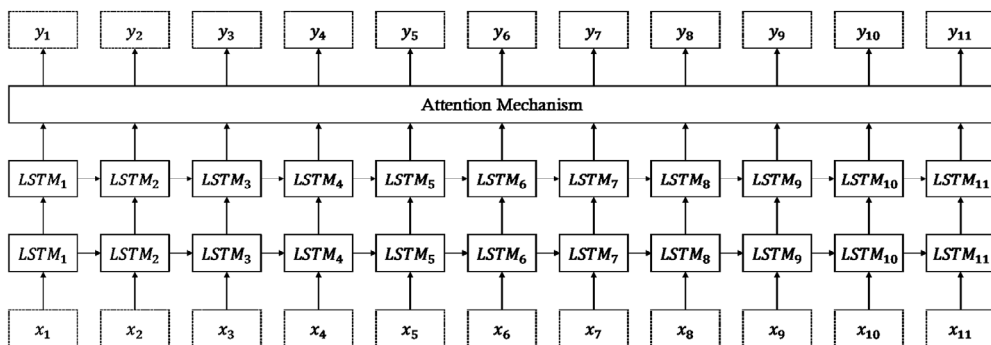


그림 2 일사량 예측을 위한 주의 집중 메커니즘 기반의 장단기 기억 네트워크 모델

Fig. 2 Attention Mechanism-based Long Short-Term Memory Model for Solar Radiation Prediction

의 집중 메커니즘 기반의 LSTM 모델(ATT-LSTM)을 나타내었다.

4. 비교 모델

본 논문에서 제안한 ATT-LSTM 일사량 예측 모델의 효율성을 입증하기 위해, 인공 신경망 기법인 SNN 모델과 이전 연구에서 제안한 DNN 및 LSTM 모델[19]들을 비교 기준 모델로 선정하였다. LSTM 모델의 구성은 3.1에서 기술하였으므로, 본 장에서는 SNN과 DNN 모델 구성에 관해 간략히 기술한다.

인공 신경망 모델은 입력층, 은닉층, 출력층으로 이루어져 있으며 이들을 구성하는 은닉 노드로 구성되어 있다[2]. 인공 신경망 모델에는 예측 성능에 영향을 주는 많은 초매개변수들이 존재한다. 초매개변수에는 은닉층의 수, 은닉층에 포함된 노드의 수, 활성화 함수 등이 있으며 은닉층의 수에 따라 네트워크의 Deep 또는 Shallow가 결정된다[20]. 여기서, 은닉층이 1개일 때에는 SNN이라 하고, 은닉층이 2개 이상일 때에는 DNN이라 한다.

Many-to-Many 방식의 구현을 위하여 하루(오전 8시부터 오후 6시까지의 11시간) 동안의 30개의 입력 변수를 모두 사용하여 총 330개의 입력 변수를 구성하였고, 하루치의 일사량 데이터를 종속 변수로 사용하였다.

4.1 Shallow Neural Network 모델

본 논문은 SNN 모델을 구성하기 위해, 초매개변수로 은닉 노드의 수는 14개, 은닉층에서 사용할 활성화 함수는 Sigmoid를 사용하였다. 또한, 손실 함수는 Mean Squared Error(MSE)를 사용하였으며, 최적화 알고리즘은 Adaptive Moment Estimation(ADAM)을 사용하였다. SNN 모델의 구성은 그림 3과 같다.




그림 3 SNN 모델

Fig. 3 SNN Model

4.2 Deep Neural Network 모델

DNN 모델은 SNN과는 다르게, 초매개변수로 은닉층의 수는 7개로, 은닉 노드의 수는 14개, 활성화 함수는 ReLU와 SELU로 설정하였다. 또한, 손실 함수는 MSE를 사용하였으며, 최적화 알고리즘은 ADAM을 사용하였다. DNN 모델은 그림 4와 같이 구성되어 있다.




그림 4 DNN 모델

Fig. 4 DNN Model

5. 실험 결과

본 논문에서는 예측 성능의 평가를 위해, 총 8년의 데이터 기간에서 2011년부터 2016년까지의 6년간의 데이터를 훈련 집합(75%)으로, 2017년부터 2018년까지의 2년간의 데이터를 평가 집합(25%)으로 구성한 데이터 셋을 SNN, DNN, LSTM, ATT-LSTM 모델에 적용하였다.

각 모델의 예측 성능을 표 2, 3, 4, 5에 시퀀스별로 나누어 상세하게 비교하였고, 표 6에서 각 모델의 평균 예측 성능을 지역별로 분류하여 상세하게 비교하였다.

예측 성능의 평가 지표로는 식 (6), (7)과 같이, Mean Absolute Error(MAE)와 Root Mean Square Error(RMSE)를 사용하였다. 수식에서 A_t 는 t 시점의 실제 일사량, F_t 는 t 시점의 예측된 일사량이며, n 은 관측치의 수이다.

$$MAE = \frac{1}{n} \sum_{t=1}^n |F_t - A_t| \quad (6)$$

$$RMSE = \sqrt{\frac{\sum_{t=1}^n (F_t - A_t)^2}{n}} \quad (7)$$

SNN 모델과 이전 연구에 사용한 모델인 DNN 및 LSTM 모델[19] 대비 ATT-LSTM 예측 모델의 MAE, RMSE가 모두 감소하였으며 가장 우수한 예측 성능을 보였다. 또한, 활성화 함수로 ReLU보다 SELU를 사용하였을 때 MAE, RMSE가 모두 감소한다는 것을 확인하였다. 이뿐만 아니라 Dropout 기법을 사용하였을 때 MAE, RMSE가 모두 감소한다는 것을 알 수 있었다.

ATT-LSTM 모델은 첫 번째 시퀀스의 MAE와 RMSE가 가장 낮았으며, 시퀀스의 숫자가 증가함에 따라 MAE와 RMSE가 증가하는 경향을 보였다. SNN, DNN

표 2 일도 1동의 모델별 MAE

Table 2 RMSE Distribution for Each Model of Ildo 1-dong

| Point | SNN | | DNN | | | | LSTM | | | | ATT-LSTM | | | |
|-------|---------|-------|-------|-------|-------|-------|-------|-------|-------|-------|----------|-------|-------|-------|
| | sigmoid | | ReLU | | SELU | | ReLU | | SELU | | ReLU | | SELU | |
| | Dropout | | | | | | | | | | | | | |
| | O | X | O | X | O | X | O | X | O | X | O | X | O | X |
| 1 | 0.588 | 0.545 | 0.545 | 0.598 | 0.392 | 0.541 | 0.544 | 0.545 | 0.408 | 0.431 | 0.381 | 0.383 | 0.329 | 0.357 |
| 2 | 0.546 | 0.532 | 0.528 | 0.548 | 0.441 | 0.526 | 0.547 | 0.550 | 0.448 | 0.467 | 0.430 | 0.428 | 0.395 | 0.415 |
| 3 | 0.537 | 0.534 | 0.529 | 0.545 | 0.465 | 0.523 | 0.545 | 0.543 | 0.462 | 0.481 | 0.446 | 0.458 | 0.431 | 0.431 |
| 4 | 0.534 | 0.533 | 0.525 | 0.525 | 0.479 | 0.512 | 0.541 | 0.544 | 0.473 | 0.492 | 0.464 | 0.466 | 0.455 | 0.450 |
| 5 | 0.528 | 0.529 | 0.519 | 0.520 | 0.487 | 0.515 | 0.540 | 0.500 | 0.484 | 0.506 | 0.478 | 0.475 | 0.464 | 0.475 |
| 6 | 0.526 | 0.526 | 0.514 | 0.518 | 0.499 | 0.511 | 0.540 | 0.543 | 0.494 | 0.507 | 0.481 | 0.496 | 0.479 | 0.509 |
| 7 | 0.524 | 0.524 | 0.513 | 0.515 | 0.506 | 0.509 | 0.547 | 0.550 | 0.506 | 0.521 | 0.491 | 0.498 | 0.502 | 0.557 |
| 8 | 0.525 | 0.524 | 0.515 | 0.514 | 0.508 | 0.509 | 0.551 | 0.551 | 0.516 | 0.531 | 0.499 | 0.512 | 0.493 | 0.538 |
| 9 | 0.524 | 0.526 | 0.519 | 0.513 | 0.522 | 0.510 | 0.559 | 0.558 | 0.517 | 0.551 | 0.505 | 0.529 | 0.508 | 0.586 |
| 10 | 0.525 | 0.529 | 0.523 | 0.514 | 0.519 | 0.511 | 0.570 | 0.567 | 0.518 | 0.551 | 0.515 | 0.530 | 0.519 | 0.598 |
| 11 | 0.528 | 0.534 | 0.527 | 0.515 | 0.532 | 0.514 | 0.636 | 0.637 | 0.519 | 0.558 | 0.528 | 0.543 | 0.528 | 0.561 |

표 3 일도1동의 모델별 MAE

Table 3 MAE Distribution for Each Model of Ildo 1-dong

| Point | SNN | | DNN | | | | LSTM | | | | ATT-LSTM | | | |
|-------|---------|-------|-------|-------|-------|-------|-------|-------|-------|-------|----------|-------|-------|-------|
| | sigmoid | | ReLU | | SELU | | ReLU | | SELU | | ReLU | | SELU | |
| | Dropout | | | | | | | | | | | | | |
| | O | X | O | X | O | X | O | X | O | X | O | X | O | X |
| 1 | 0.445 | 0.413 | 0.419 | 0.445 | 0.349 | 0.408 | 0.365 | 0.380 | 0.318 | 0.357 | 0.291 | 0.272 | 0.238 | 0.261 |
| 2 | 0.406 | 0.390 | 0.384 | 0.401 | 0.327 | 0.383 | 0.388 | 0.399 | 0.332 | 0.379 | 0.324 | 0.299 | 0.291 | 0.301 |
| 3 | 0.394 | 0.393 | 0.389 | 0.398 | 0.343 | 0.380 | 0.409 | 0.417 | 0.350 | 0.400 | 0.329 | 0.324 | 0.311 | 0.307 |
| 4 | 0.390 | 0.392 | 0.386 | 0.387 | 0.354 | 0.378 | 0.412 | 0.426 | 0.360 | 0.412 | 0.340 | 0.332 | 0.330 | 0.319 |
| 5 | 0.386 | 0.390 | 0.382 | 0.384 | 0.363 | 0.376 | 0.420 | 0.431 | 0.372 | 0.413 | 0.347 | 0.339 | 0.333 | 0.343 |
| 6 | 0.385 | 0.388 | 0.379 | 0.385 | 0.368 | 0.374 | 0.427 | 0.442 | 0.377 | 0.438 | 0.348 | 0.351 | 0.346 | 0.376 |
| 7 | 0.385 | 0.387 | 0.380 | 0.383 | 0.375 | 0.373 | 0.436 | 0.456 | 0.371 | 0.446 | 0.357 | 0.349 | 0.368 | 0.414 |
| 8 | 0.386 | 0.387 | 0.382 | 0.381 | 0.382 | 0.373 | 0.436 | 0.467 | 0.373 | 0.467 | 0.363 | 0.360 | 0.348 | 0.386 |
| 9 | 0.385 | 0.388 | 0.385 | 0.381 | 0.395 | 0.374 | 0.446 | 0.468 | 0.378 | 0.488 | 0.368 | 0.375 | 0.358 | 0.439 |
| 10 | 0.385 | 0.391 | 0.388 | 0.381 | 0.395 | 0.376 | 0.458 | 0.470 | 0.379 | 0.501 | 0.382 | 0.378 | 0.371 | 0.452 |
| 11 | 0.385 | 0.395 | 0.391 | 0.381 | 0.405 | 0.378 | 0.460 | 0.470 | 0.370 | 0.517 | 0.394 | 0.392 | 0.381 | 0.415 |

표 4 고산리의 모델별 RMSE

Table 4 RMSE Distribution for Each Model of Gosanri

| Point | SNN | | DNN | | | | LSTM | | | | ATT-LSTM | | | |
|-------|---------|-------|-------|-------|-------|-------|-------|-------|-------|-------|----------|-------|-------|-------|
| | sigmoid | | ReLU | | SELU | | ReLU | | SELU | | ReLU | | SELU | |
| | Dropout | | | | | | | | | | | | | |
| | O | X | O | X | O | X | O | X | O | X | O | X | O | X |
| 1 | 0.559 | 0.518 | 0.522 | 0.552 | 0.366 | 0.532 | 0.400 | 0.455 | 0.375 | 0.406 | 0.306 | 0.338 | 0.297 | 0.322 |
| 2 | 0.533 | 0.518 | 0.519 | 0.522 | 0.407 | 0.519 | 0.420 | 0.462 | 0.380 | 0.417 | 0.370 | 0.416 | 0.360 | 0.380 |
| 3 | 0.528 | 0.520 | 0.519 | 0.523 | 0.431 | 0.521 | 0.437 | 0.477 | 0.410 | 0.451 | 0.403 | 0.445 | 0.401 | 0.415 |
| 4 | 0.531 | 0.517 | 0.512 | 0.522 | 0.452 | 0.517 | 0.442 | 0.484 | 0.444 | 0.471 | 0.435 | 0.490 | 0.436 | 0.432 |
| 5 | 0.530 | 0.512 | 0.506 | 0.520 | 0.469 | 0.514 | 0.451 | 0.491 | 0.467 | 0.490 | 0.454 | 0.541 | 0.452 | 0.456 |
| 6 | 0.527 | 0.506 | 0.500 | 0.520 | 0.484 | 0.511 | 0.462 | 0.500 | 0.486 | 0.496 | 0.485 | 0.539 | 0.473 | 0.470 |
| 7 | 0.525 | 0.502 | 0.496 | 0.521 | 0.490 | 0.509 | 0.473 | 0.511 | 0.492 | 0.500 | 0.497 | 0.569 | 0.500 | 0.485 |
| 8 | 0.526 | 0.501 | 0.495 | 0.521 | 0.503 | 0.509 | 0.488 | 0.531 | 0.510 | 0.508 | 0.495 | 0.527 | 0.515 | 0.499 |
| 9 | 0.523 | 0.499 | 0.495 | 0.521 | 0.516 | 0.510 | 0.501 | 0.547 | 0.526 | 0.522 | 0.508 | 0.566 | 0.529 | 0.511 |
| 10 | 0.522 | 0.497 | 0.496 | 0.522 | 0.514 | 0.511 | 0.511 | 0.567 | 0.533 | 0.547 | 0.515 | 0.586 | 0.524 | 0.522 |
| 11 | 0.521 | 0.497 | 0.497 | 0.526 | 0.524 | 0.511 | 0.511 | 0.580 | 0.538 | 0.555 | 0.517 | .0581 | 0.526 | 0.524 |

표 5 고산리의 모델별 MAE

Table 5 RMSE Distribution for Each Model of Gosanri

| Point | SNN | | DNN | | | | LSTM | | | | ATT-LSTM | | | |
|-------|---------|-------|-------|-------|-------|-------|-------|-------|-------|-------|----------|-------|-------|-------|
| | sigmoid | | ReLU | | SELU | | ReLU | | SELU | | ReLU | | SELU | |
| | Dropout | | | | | | | | | | | | | |
| | O | X | O | X | O | X | O | X | O | X | O | X | O | X |
| 1 | 0.426 | 0.388 | 0.409 | 0.421 | 0.278 | 0.409 | 0.345 | 0.377 | 0.298 | 0.340 | 0.221 | 0.240 | 0.219 | 0.231 |
| 2 | 0.399 | 0.375 | 0.381 | 0.399 | 0.306 | 0.381 | 0.358 | 0.399 | 0.312 | 0.351 | 0.265 | 0.295 | 0.262 | 0.273 |
| 3 | 0.391 | 0.374 | 0.377 | 0.387 | 0.325 | 0.380 | 0.359 | 0.401 | 0.320 | 0.352 | 0.289 | 0.311 | 0.289 | 0.297 |
| 4 | 0.387 | 0.370 | 0.373 | 0.394 | 0.343 | 0.375 | 0.362 | 0.408 | 0.340 | 0.357 | 0.317 | 0.346 | 0.316 | 0.310 |
| 5 | 0.381 | 0.364 | 0.370 | 0.384 | 0.355 | 0.370 | 0.370 | 0.415 | 0.352 | 0.360 | 0.332 | 0.385 | 0.327 | 0.327 |
| 6 | 0.377 | 0.360 | 0.369 | 0.379 | 0.365 | 0.367 | 0.377 | 0.420 | 0.367 | 0.361 | 0.365 | 0.383 | 0.340 | 0.338 |
| 7 | 0.373 | 0.358 | 0.367 | 0.371 | 0.367 | 0.364 | 0.386 | 0.422 | 0.371 | 0.369 | 0.377 | 0.409 | 0.354 | 0.347 |
| 8 | 0.374 | 0.357 | 0.367 | 0.388 | 0.379 | 0.363 | 0.376 | 0.421 | 0.383 | 0.372 | 0.365 | 0.384 | 0.363 | 0.359 |
| 9 | 0.375 | 0.357 | 0.369 | 0.401 | 0.388 | 0.365 | 0.376 | 0.421 | 0.388 | 0.371 | 0.366 | 0.416 | 0.376 | 0.367 |
| 10 | 0.374 | 0.356 | 0.367 | 0.399 | 0.387 | 0.367 | 0.378 | 0.421 | 0.389 | 0.371 | 0.371 | 0.445 | 0.378 | 0.376 |
| 11 | 0.373 | 0.355 | 0.374 | 0.389 | 0.397 | 0.367 | 0.380 | 0.420 | 0.390 | 0.371 | 0.373 | 0.442 | 0.383 | 0.380 |

표 6 예측 성능 비교

Table 6 Prediction Performance Comparison

| Prediction Model | Activation Function | Dropout | Ildo 1-dong | | Gosanri | |
|------------------|---------------------|---------|-------------|-------|---------|-------|
| | | | RMSE | MAE | RMSE | MAE |
| SNN | sigmoid | O | 0.521 | 0.417 | 0.622 | 0.686 |
| | | X | 0.539 | 0.434 | 0.634 | 0.696 |
| DNN | ReLU | O | 0.492 | 0.355 | 0.525 | 0.556 |
| | | X | 0.511 | 0.371 | 0.533 | 0.570 |
| | SELU | O | 0.467 | 0.338 | 0.482 | 0.554 |
| | | X | 0.489 | 0.352 | 0.502 | 0.524 |
| LSTM | ReLU | O | 0.482 | 0.353 | 0.491 | 0.362 |
| | | X | 0.501 | 0.411 | 0.498 | 0.432 |
| | SELU | O | 0.470 | 0.348 | 0.507 | 0.370 |
| | | X | 0.477 | 0.397 | 0.500 | 0.402 |
| ATT-LSTM | ReLU | O | 0.394 | 0.350 | 0.403 | 0.331 |
| | | X | 0.455 | 0.470 | 0.441 | 0.464 |
| | SELU | O | 0.388 | 0.334 | 0.396 | 0.327 |
| | | X | 0.450 | 0.461 | 0.437 | 0.458 |

모델은 Point에 따른 변화가 크지 않았으며 모두 고른 성능을 보였다. 전체적으로, ATT-LSTM 모델의 예측 성능이 SNN, DNN 모델과 LSTM 모델보다 우수함을 확인할 수 있었다.

6. 결론

본 논문에서는 스마트 아일랜드를 위한 정교한 일사량 예측을 위해, 일기예보에서 제공하는 기상 요인을 이용하여 주의 집중 장단기 메모리 네트워크 기반의 확률론적 단기 일사량 예측 기법을 제안하였다. 먼저 하루 뒤의 일사량을 예측하기 위해, 하루 뒤 정보를 반영할 수 있도록 입력 변수를 구성하였다. 다음으로 장단기 메모리 네트워크를 이용하여 예측 모델을 구축하였으며, 주의 집중 메커니즘을 이용하여 예측 모델의 예측 성능

을 개선했다. 그리하여, 제주도를 대상으로 다양한 실험에서 제안한 기법이 다른 심층 학습 기법보다 더욱 정교한 예측 성능이 보임을 확인하였다.

향후 기상청의 일기예보에서 제공하지 않는 운량과 기압 등의 기상 요인들을 예측하여 예측 모델의 입력 변수로 반영할 계획이다. 더불어 일사량을 태양광 발전 시스템 예측 모델에 반영하여 태양광 발전량 예측 및 태양광 발전시스템의 스케줄링을 함께 연구할 계획이다.

References

- [1] J. Moon, K.-H. Kim, Y. Kim, and E. Hwang, "A Short-Term Electric Load Forecasting Scheme Using 2-Stage Predictive Analytics," *Proc. of the 2018 IEEE International Conference on Big Data and Smart Computing (BigComp)*, pp. 219-226, 2018.

- [2] J. Moon, J. Park, E. Hwang, and S. Jun, "Forecasting power consumption for higher educational institutions based on machine learning," *The Journal of Supercomputing*, Vol. 74, No. 8, pp. 3778-3800, 2018.
- [3] M. Son, J. Moon, S. Jung, and E. Hwang, "A Short-Term Load Forecasting Scheme Based on Auto-Encoder and Random Forest," *Proc. of the 3rd International Conference on Applied Physics, System Science and Computers*, pp. 138-144, 2018.
- [4] Jeju Special Self-Governing Province. Networks [Online]. Available: <https://www.jeju.go.kr/index.htm>
- [5] D. Yang, N. Yeo, and P. Mah, "A Dynamic Piecewise Prediction Model of Solar Insolation for Efficient Photovoltaic Systems," *KIISE Transactions on Computing Practices*, Vol. 23, No. 11, pp. 632-640, 2017.
- [6] A. Khosravi, R. N. N. Koury, L. Machado, and J. J. G. Pabon, "Prediction of hourly solar radiation in Abu Musa Island using machine learning algorithms," *Journal of Cleaner Production*, Vol. 176, pp. 63-75, 2018.
- [7] R. Meenal and A. Selvakumar, "Assessment of SVM, empirical and ANN based solar radiation prediction models with most influencing input parameters," *Renewable Energy*, Vol. 121, pp. 324-343, 2018.
- [8] A. Yadav and S. Chandel, "Solar radiation prediction using Artificial Neural Network techniques: A review," *Renewable and Sustainable Energy Reviews*, Vol. 33, pp. 772-781, 2014.
- [9] Z. Qingyuan, J. Huang, and L. Siwei, "Development of Typical Year Weather Data for Chinese Location," *The American Society of Heating Refrigerating and Air-Conditioning Engineers*, Vol. 108, No. 2, 2002.
- [10] J. Jeong and Y. Chae, "Improvement for Forecasting of Photovoltaic Power Output using Real Time Weather Data based on Machine Learning," *Journal of Korean Society of Living Environmental System*, Vol. 25, No. 1, pp. 119-125, 2018.
- [11] D. Shin and C. Kim, "Short Term Forecast Model for Solar Power Generation using RNN-LSTM," *Journal of Advanced Navigation Technology*, Vol. 22, No. 3, pp. 233-239, Jun. 2018.
- [12] J. Kim, J. Moon, E. Hwang, and P. Kang, "Recurrent inception convolution neural network for multi short-term load forecasting," *Energy and Buildings*, Vol. 194, pp. 328-341, 2019.
- [13] S. Hochreiter and J. Schmidhuber, "Long Short Term Memory," *Neural Computation*, Vol. 9, No. 8, pp. 1735-1780, 1997.
- [14] H. Li, Y. Shen, and Y. Zhu, "Stock Price Prediction Using Attention-based Multi-Input LSTM," *Proc. of the Asian Conference on Machine Learning Research*, Vol. 95, pp. 454-469, 2018.
- [15] D. Bahdanau, K. Cho, and Y. Bengio, "Neural Machine Translation by Jointly Learning to Align and Translate," *Proc. of the International Conference on Learning Representations*, 2015.
- [16] G. Klambauer, T. Unterthiner, and A. Mayr, "Self-Normalizing Neural Networks," *Proc. of the International Conference on Neural Information Processing Systems*, 2017.
- [17] J. Niu, J. Chen, and Y. Xu, "Twin support vector regression with Huber loss," *Journal of Intelligent and Fuzzy Systems*, Vol. 32, No. 6, pp. 4247-4258, 2017.
- [18] G. Hinton, N. Srivastava, and K. Swersky, "Neural networks for machine learning lecture 6a overview of mini-batch gradient descent," 2012.
- [19] S. Jung, J. Moon, S. Park, and E. Hwang, "Deep Learning-Based Solar Radiation Prediction for Jeju Island," *Proc. of the KIISE Korea Computer Congress 2019*, pp. 460-461, 2019.
- [20] J. Moon, Y. Kim, M. Son, and E. Hwang, "Hybrid Short-Term Load Forecasting Scheme Using Random Forest and Multilayer Perceptron," *Energies*, Vol. 11, No. 12, p. 3283, 2018.



정 승 민

2018년 고려대학교 전기전자공학과 졸업 (학사). 2018년~현재 고려대학교 전기전자공학과 석·박사통합과정. 관심분야는 인공 지능, 앙상블 학습, 데이터 마이닝, 스마트 그리드, 신재생 에너지 등



문 지 훈

2015년 한성대학교 정보통신공학과(학사) 2015년~현재 고려대학교 전기전자공학과 석·박사통합과정. 관심분야는 스마트 그리드, 시계열 분석, 기계 학습, 데이터 마이닝 등



박 성 우

2018년 홍익대학교 컴퓨터공학과(학사) 2018년~현재 고려대학교 전기전자공학과 석·박사통합과정. 관심분야는 데이터 마이닝, 빅 데이터 분석, 인공 지능, 수요 예측 등



황 인 준

1988년 서울대학교 컴퓨터공학과(학사). 1990년 서울대학교 컴퓨터공학과(석사). 1998년 Univ. of Maryland at College Park 전산학과(박사). 1998년~1999년 Bowie State Univ. 조교수. 1999년 Hughes Research Lab. 연구교수. 1999년~2004년 아주대학교 정보통신전문대학원 조/부교수. 2004년~현재 고려대학교 전기전자공학과 정교수. 관심분야는 데이터베이스, 빅 데이터 처리, 정보 검색, 영상 처리, 의료 애플리케이션 등